

爬虫与信息系统 大作业 report

——By 杨博钧 2025012810

爬虫

爬取网站：酷狗音乐

爬取歌曲的思路：歌手列表 -> 歌手 -> 歌手主页 -> 歌曲

1. 注意到酷狗音乐有歌手栏，直接从歌手列表中爬取，按照歌手姓名的拼音顺序A-Z爬取
2. 爬取到足够歌手后，依次跳转进每个歌手的主页，爬取歌曲，每个歌手爬取约20-30首歌
3. 跳转进歌曲页面，爬取歌曲信息（时长，歌词，发行时间）

算法：主要使用 `requests` 进行爬取，爬取歌曲页面时使用 `playwright` 爬取歌词等

爬取总数：歌曲数 2074 首，歌手数 120 人

Web

使用 Django 框架进行开发

主要功能

1. **歌曲列表：**以网格形式展示所有歌曲，支持分页（每页12条），随机排序
2. **歌曲详情：**展示歌曲封面、歌手、歌词等信息，支持用户发表评论，评论按时间倒序排列
3. **歌手列表：**按ID顺序展示所有歌手，支持分页
4. **歌手详情：**展示歌手头像、简介，以及该歌手的全部歌曲
5. **搜索功能：**支持按歌曲名、歌手名、歌词内容搜索，也可单独按歌手名搜索，结果分页展示，并显示搜索耗时
6. **评论管理：**支持删除评论

数据模型

- **Singer** (歌手)：id、name、intro、url、image
- **Song** (歌曲)：id、name、singer (外键)、url、image、lyrics
- **Comment** (评论)：id、song (外键)、content、release_time

技术细节

- 歌曲列表使用 `select_related` 预加载歌手信息，减少数据库查询

- 分页导航栏使用自定义算法，显示首尾页 + 当前页附近页码 + 省略号
- 搜索支持模糊匹配（icontains），结果去重

数据分析

算法与技术

- **词云生成**：中文歌使用 jieba 分词进行词语切分，英文歌按空格切分；使用 Counter 进行词频统计，滤去高频虚词和语气词后，用 wordcloud 库生成词云图
- **相似歌手关系图**：从歌手主页爬取"相似歌手"栏目，以 BFS（广度优先搜索）递归爬取，使用 networkx 构建有向图，matplotlib 进行可视化
- **歌曲时长分析**：对时长（ms）按分钟区间分组统计，使用饼状图展示各区间占比
- **发行时间统计**：爬取专辑发行时间，分别按年份和月份统计分布